Apuntes de Inferencia Estadística

Profesor: Nicolás Zalduendo

Universidad de Santiago de Chile

2026

Autor: *(Nicolás Aguilar)*

12 de abril de 2026

Índice

1. Tópicos en Probabilidad **2**
1.1. Espacios de trabajo 2
1.2. Variable aleatoria y ley 2
1.3. Función de distribución acumulada 2
1.4. Esperanza 3
1.5. Espacios L^p 3
1.6. Covarianza y Varianza 3
1.7. Leyes clásicas: 4
1.8. Leyes absolutamente continuas 4
1.9. Independencia 5
1.10. Función característica 9
1.11. Esperanza condicional 12
1.12. Modos de convergencia 18

1. Tópicos en Probabilidad

Para comprender la inferencia estadística, es fundamental contar con una base sólida en probabilidad. En esta sección se introducen los conceptos que establecerán el marco teórico del curso.

1.1. Espacios de trabajo

Sea $(\Omega, \mathcal{F}, P)$ un **espacio de probabilidad**, donde:

- Ω es el espacio muestral,
- $\mathcal{F}$ es una σ-álgebra de subconjuntos de Ω,
- P es una medida de probabilidad.

Consideraremos además un **espacio medible** $(\mathcal{E}, \mathcal{B}(\mathcal{E}))$, donde $\mathcal{E}$ es el espacio de valores y $\mathcal{B}(\mathcal{E})$ su σ-álgebra de Borel.

1.2. Variable aleatoria y ley

Definición 1.1 (Variable aleatoria)**.** Una variable aleatoria con valores en $\mathcal{E}$ es una función medible

$$X : \Omega \to \mathcal{E}.$$

La medibilidad significa que, para todo $A \in \mathcal{B}(\mathcal{E})$,

$$X^{-1}(A) = \{\omega \in \Omega : X(\omega) \in A\} \in \mathcal{F}.$$

Definición 1.2 (Ley de una variable aleatoria)**.** La **ley** de X es la medida de probabilidad P_X sobre $\mathcal{E}$ definida por

$$P_X(A) = P(X^{-1}(A)), \quad \forall A \in \mathcal{B}(\mathcal{E}).$$

Equivalente y compactamente, se escribe

$$P_X = P \circ X^{-1},$$

y se conoce como la **medida imagen** (o *pushforward*) de P por X.

1.3. Función de distribución acumulada

Cuando $\mathcal{E} = \mathbb{R}$, la ley de X puede describirse mediante su función de distribución acumulada.

Definición 1.3 (Función de distribución acumulada (FDA))**.** La FDA de X es la función $F_X : \mathbb{R} \to [0, 1]$ definida por

$$\begin{aligned} F_X : \mathbb{R} &\to [0, 1] \\ x &\mapsto P(X \leq x) = P_X((-\infty, x]). \end{aligned}$$

La FDA determina completamente la ley de X, ya que permite reconstruir la medida P_X sobre la σ-álgebra de Borel.

1.4. Esperanza

Definición 1.4 (Esperanza)**.** Si X es integrable, su esperanza se define por

$$\mathbb{E}[X] = \int_\Omega X(\omega)\, dP(\omega).$$

Mediante el Teorema del Transporte, esta puede expresarse en términos de la ley de X:

$$\mathbb{E}[X] = \int_{\mathbb{R}} x\, dP_X(x).$$

1.5. Espacios L^p

Surge naturalmente la pregunta: *¿para qué variables aleatorias está bien definida la esperanza?*

Para responderla, introducimos los espacios L^p. Para $1 \leq p < \infty$, definimos

$$L^p(\Omega, \mathcal{F}, P) = \{X : \mathbb{E}[|X|^p] < \infty\}.$$

En particular:

- $X \in L^1$ si y solo si $\mathbb{E}[|X|] < \infty$,
- en este caso, la esperanza $\mathbb{E}[X]$ está bien definida.

Además, como P es una medida de probabilidad (finita), se tiene que

$$L^p \subseteq L^1 \quad \text{para todo } p \geq 1.$$

Sin embargo, la inclusión es estricta: existen variables en L^1 que no pertenecen a ningún L^p con $p > 1$.

Conclusión: el espacio natural donde la esperanza está bien definida es $L^1(\Omega, \mathcal{F}, P)$.

1.6. Covarianza y Varianza

Primero las definimos:

Definición 1.5 (Covarianza)**.** La covarianza entre dos variables aleatorias X e Y es definida por

$$\mathrm{Cov}(X, Y) = \mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])].$$

Definición 1.6 (Varianza)**.** La varianza de una variable aleatoria X es definida por

$$\mathrm{Var}(X) = \mathbb{E}[(X - \mathbb{E}[X])^2].$$

Observación: la varianza es un caso particular de covarianza, ya que $\mathrm{Var}(X) = \mathrm{Cov}(X, X)$ y además si $X, Y \in L^2$ entonces $\langle X, Y \rangle_{L^2} = \mathrm{Cov}(X, Y) = \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y]$.

1.7. Leyes clásicas:

Distribuciones discretas ($\mathcal{E} = \mathbb{R}$):

- **Bernoulli:** $X \sim \text{Bern}(p)$ con $P(X = 1) = p$ y $P(X = 0) = 1 - p$. La ley es:
$$P_X = p\,\delta_1 + (1-p)\,\delta_0,$$
y por ende, la esperanza:
$$\mathbb{E}[X] = \int_{\mathbb{R}} x\,dP_X(x) = \int_{\mathbb{R}} x\,d(p\,\delta_1 + (1-p)\,\delta_0)(x) = p.$$
- **Binomial:** $X \sim \text{Bin}(n, p)$ con $n \in \mathbb{N}$ y $p \in [0, 1]$. La ley es:
$$P_X = \sum_{k=0}^{n} \binom{n}{k} p^k (1-p)^{n-k}\,\delta_k,$$
y por ende, la esperanza:
$$\mathbb{E}[X] = \sum_{k=0}^{n} k\,dP_X(k) = \sum_{k=0}^{n} k \binom{n}{k} p^k (1-p)^{n-k} = np.$$
- **Poisson:** $X \sim \text{Poi}(\lambda)$ con $\lambda > 0$. La ley es:
$$P_X = \sum_{k=0}^{\infty} e^{-\lambda} \frac{\lambda^k}{k!}\,\delta_k,$$
y por ende, la esperanza:
$$\mathbb{E}[X] = \sum_{k=0}^{\infty} k\,dP_X(k) = \sum_{k=0}^{\infty} k\,e^{-\lambda} \frac{\lambda^k}{k!} = \lambda.$$

1.8. Leyes absolutamente continuas

Hasta ahora hemos descrito leyes discretas mediante combinaciones de deltas de Dirac. Sin embargo, muchas variables aleatorias de interés toman valores en $\mathbb{R}$ de manera continua.

Sea λ la **medida de Lebesgue** en $\mathbb{R}$.

Definición 1.7 (Medida absolutamente continua)**.** Decimos que la ley P_X es **absolutamente continua** respecto de la medida de Lebesgue, y escribimos
$$P_X \ll \lambda,$$
si para todo conjunto boreliano A,
$$\lambda(A) = 0 \implies P_X(A) = 0.$$

Este concepto es fundamental, ya que permite introducir densidades.

Teorema 1.1 (Radon–Nikodym)**.** *Si $P_X \ll \lambda$, entonces existe una función medible $f_X : \mathbb{R} \to [0, \infty)$ tal que*
$$P_X(A) = \int_A f_X(x)\,dx, \quad \forall A \in \mathcal{B}(\mathbb{R}).$$

La función f_X se denomina **densidad** de X, y se escribe formalmente
$$P_X(dx) = f_X(x)\,dx.$$

Consecuencias

Si X admite densidad f_X, entonces:

- La probabilidad de un conjunto se calcula como

$$P(X \in A) = \int_A f_X(x)\,dx.$$

- La esperanza puede escribirse como

$$\mathbb{E}[X] = \int_{\mathbb{R}} x f_X(x)\,dx.$$

Ejemplos clásicos

- **Uniforme:** $X \sim \mathcal{U}(a,b)$

$$f_X(x) = \frac{1}{b-a} \mathbb{1}_{[a,b]}(x)$$

- **Exponencial:** $X \sim \mathrm{Exp}(\lambda)$

$$f_X(x) = \lambda e^{-\lambda x} \mathbb{1}_{[0,\infty)}(x)$$

- **Normal:** $X \sim \mathcal{N}(\mu, \sigma^2)$

$$f_X(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$$

Interpretación: en el caso discreto, la ley se escribe como suma de deltas; en el caso continuo, como una densidad respecto a la medida de Lebesgue. Ambos enfoques son unificados mediante la noción de medida.

1.9. Independencia

La noción de independencia puede formularse tanto en términos de eventos como en términos de leyes.

Recordatorio: si $X : \Omega \to \mathcal{E}$ es una variable aleatoria, entonces X induce la σ-álgebra

$$\sigma(X) = \{X^{-1}(A) : A \in \mathcal{B}(\mathcal{E})\}.$$

En este sentido, la independencia de variables aleatorias puede entenderse como independencia entre las σ-álgebras que ellas generan.

Definición 1.8 (Variables aleatorias independientes)**.** Sean $X_1, \ldots, X_n$ variables aleatorias con valores en $\mathcal{E}$. Diremos que son **independientes** si para todo $B_1, \ldots, B_n \in \mathcal{B}(\mathcal{E})$ se tiene

$$P(X_1 \in B_1, \ldots, X_n \in B_n) = \prod_{i=1}^{n} P(X_i \in B_i).$$

Dicho de otra forma, la ley de la variable aleatoria vectorial

$$(X_1, \ldots, X_n) : \Omega \to \mathcal{E}^n$$

satisface

$$P_{(X_1,\ldots,X_n)} = P_{X_1} \otimes P_{X_2} \otimes \cdots \otimes P_{X_n}.$$

En efecto, para todo $B_1, \ldots, B_n \in \mathcal{B}(\mathcal{E})$,

$$P_{(X_1,\ldots,X_n)}(B_1 \times \cdots \times B_n) = P\big((X_1, \ldots, X_n) \in B_1 \times \cdots \times B_n\big),$$

y por definición de la variable aleatoria vectorial,

$$P\big((X_1, \ldots, X_n) \in B_1 \times \cdots \times B_n\big) = P(X_1 \in B_1, \ldots, X_n \in B_n).$$

Por otra parte,

$$(P_{X_1} \otimes \cdots \otimes P_{X_n})(B_1 \times \cdots \times B_n) = \prod_{i=1}^{n} P_{X_i}(B_i) = \prod_{i=1}^{n} P(X_i \in B_i).$$

Luego, la independencia equivale a que la ley conjunta coincida con el producto de las leyes marginales.

Observación: no debe confundirse independencia conjunta con independencia dos a dos.

Decimos que $X_1, \ldots, X_n$ son **independientes dos a dos** si para todo $i \neq j$, las variables X_i y X_j son independientes.

En general,

$$\text{independencia conjunta} \implies \text{independencia dos a dos},$$

pero el recíproco es falso.

Ejemplo

Sean X e Y variables aleatorias i.i.d. con ley Bernoulli(1/2) y definamos

$$Z = X + Y \quad (\text{mód } 2).$$

Entonces (X, Y, Z) son independientes dos a dos, pero no son independientes conjuntamente.

En efecto, existe una relación determinista entre ellas:

$$Z = X + Y \quad (\text{mód } 2).$$

Por tanto, conocer X e Y determina completamente a Z, lo que impide la independencia mutua.

Por ejemplo,

$$P(X = 0, Y = 0, Z = 1) = 0,$$

mientras que

$$P(X = 0)\, P(Y = 0)\, P(Z = 1) = \frac{1}{2} \cdot \frac{1}{2} \cdot \frac{1}{2} = \frac{1}{8}.$$

Como

$$0 \neq \frac{1}{8},$$

se concluye que X, Y y Z no son independientes.

Factorización de esperanzas

La independencia permite factorizar esperanzas de productos de funciones, como veremos a continuación:

Proposición: si $X_1, \ldots, X_n$ son independientes y $h_1, \ldots, h_n : \mathcal{E} \to \mathbb{R}$ son medibles y no negativas, entonces

$$\mathbb{E}\left[\prod_{i=1}^{n} h_i(X_i)\right] = \prod_{i=1}^{n} \mathbb{E}[h_i(X_i)].$$

Más generalmente, la igualdad sigue siendo válida siempre que las cantidades involucradas estén bien definidas.

Demostración

Sea

$$H : \mathcal{E}^n \to \mathbb{R}$$

definida por

$$H(x_1, \ldots, x_n) = h_1(x_1)\, h_2(x_2) \cdots h_n(x_n).$$

Luego,

$$\mathbb{E}\left[\prod_{i=1}^{n} h_i(X_i)\right] = \mathbb{E}\big(H(X_1, \ldots, X_n)\big).$$

Por el Teorema del Transporte,

$$\mathbb{E}\big(H(X_1, \ldots, X_n)\big) = \int_{\mathcal{E}^n} H(x_1, \ldots, x_n)\, dP_{(X_1,\ldots,X_n)}(x_1, \ldots, x_n).$$

Como $X_1, \ldots, X_n$ son independientes,

$$P_{(X_1,\ldots,X_n)} = P_{X_1} \otimes \cdots \otimes P_{X_n}.$$

Por lo tanto,

$$\int_{\mathcal{E}^n} H(x_1, \ldots, x_n)\, dP_{(X_1,\ldots,X_n)} = \int_{\mathcal{E}^n} h_1(x_1) \cdots h_n(x_n)\, d(P_{X_1} \otimes \cdots \otimes P_{X_n}).$$

Aplicando Tonelli–Fubini,

$$\int_{\mathcal{E}^n} h_1(x_1) \cdots h_n(x_n)\, d(P_{X_1} \otimes \cdots \otimes P_{X_n})$$

$$= \int_{\mathcal{E}} h_1(x_1)\, dP_{X_1}(x_1) \cdots \int_{\mathcal{E}} h_n(x_n)\, dP_{X_n}(x_n).$$

Finalmente, para cada i,

$$\int_{\mathcal{E}} h_i(x_i)\, dP_{X_i}(x_i) = \mathbb{E}[h_i(X_i)].$$

Así,

$$\mathbb{E}\left[\prod_{i=1}^{n} h_i(X_i)\right] = \prod_{i=1}^{n} \mathbb{E}[h_i(X_i)].$$

□

Observación: el resultado sigue siendo válido si

$$\mathbb{E}[|h_i(X_i)|] < \infty, \qquad i = 1, \ldots, n.$$

En ese caso,

$$\mathbb{E}\left[\prod_{i=1}^{n} |h_i(X_i)|\right] = \prod_{i=1}^{n} \mathbb{E}[|h_i(X_i)|] < \infty,$$

por lo que el producto es integrable y puede aplicarse Fubini.

Corolario: si $X \perp Y$ y $X, Y \in L^2$, entonces

$$\mathrm{Cov}(X, Y) = 0.$$

Demostración: por independencia,

$$\mathbb{E}[XY] = \mathbb{E}[X]\mathbb{E}[Y].$$

Luego,

$$\mathrm{Cov}(X, Y) = \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y] = 0.$$

□

Última observación: la recíproca es falsa en general:

$$\mathrm{Cov}(X, Y) = 0 \not\Longrightarrow X \perp Y.$$

Recordatorio

Recordemos que, si $X : \Omega \to \mathbb{R}$ es una variable aleatoria y $h : \mathbb{R} \to \mathbb{R}$ es medible, entonces

$$\mathbb{E}[h(X)] = \int_{\mathbb{R}} h(x)\, P_X(dx),$$

siempre que la integral esté bien definida.

(1) Caso absolutamente continuo. Si X es absolutamente continua, entonces existe una densidad f_X tal que

$$P_X(dx) = f_X(x)\, dx.$$

Luego,

$$\mathbb{E}[h(X)] = \int_{\mathbb{R}} h(x)\, P_X(dx) = \int_{\mathbb{R}} h(x) f_X(x)\, dx.$$

(2) Caso discreto. Si la ley de X es discreta, por ejemplo con soporte en $\mathbb{N}$, entonces

$$P_X(dx) = \sum_{k \in \mathbb{N}} P(X = k)\, \delta_k(dx).$$

Por lo tanto,

$$\mathbb{E}[h(X)] = \int_{\mathbb{R}} h(x)\, P_X(dx)$$

$$= \int_{\mathbb{R}} h(x) \left(\sum_{k \in \mathbb{N}} P(X = k)\, \delta_k(dx) \right).$$

Intercambiando suma e integral,

$$\mathbb{E}[h(X)] = \sum_{k\in\mathbb{N}} P(X = k) \int_{\mathbb{R}} h(x)\, \delta_k(dx).$$

Como

$$\int_{\mathbb{R}} h(x)\, \delta_k(dx) = h(k),$$

se obtiene

$$\mathbb{E}[h(X)] = \sum_{k\in\mathbb{N}} h(k)\, P(X = k).$$

1.10. Función característica

Sea X una variable aleatoria con valores en $\mathbb{R}^d$, es decir,

$$X = (X_1, \ldots, X_d).$$

La **función característica** de X es la función

$$\varphi_X : \mathbb{R}^d \to \mathbb{C}$$

definida por

$$\varphi_X(t) = \mathbb{E}\big(e^{i\langle t, X\rangle}\big), \qquad t \in \mathbb{R}^d.$$

Si $t = (t_1, \ldots, t_d)$, entonces

$$\langle t, X\rangle = \sum_{j=1}^{d} t_j X_j,$$

y por lo tanto

$$\varphi_X(t) = \mathbb{E}\left(\exp\left(i \sum_{j=1}^{d} t_j X_j\right)\right).$$

Observación: la función característica puede verse como una versión probabilística de la transformada de Fourier de la ley de X, pues

$$\varphi_X(t) = \int_{\mathbb{R}^d} e^{i\langle t, x\rangle}\, P_X(dx).$$

Casos particulares

Si X tiene densidad f_X en $\mathbb{R}^d$, entonces

$$\varphi_X(t) = \int_{\mathbb{R}^d} e^{i\langle t, x\rangle} f_X(x)\, dx.$$

Si X es discreta con valores $x_k \in \mathbb{R}^d$, entonces

$$\varphi_X(t) = \sum_k e^{i\langle t, x_k\rangle} P(X = x_k).$$

Observación

Si X es una variable aleatoria real, entonces su función característica viene dada por

$$\varphi_X(t) = \mathbb{E}(e^{itX}) = \int_{\mathbb{R}} e^{itx}\, P_X(dx).$$

Si además X es absolutamente continua con densidad f_X, entonces

$$P_X(dx) = f_X(x)\, dx,$$

y por lo tanto

$$\varphi_X(t) = \int_{\mathbb{R}} e^{itx}\, P_X(dx) = \int_{\mathbb{R}} e^{itx} f_X(x)\, dx.$$

Ejemplos

(1) Si $X \sim \text{Bernoulli}(p)$, entonces

$$\varphi_X(t) = \mathbb{E}(e^{itX}).$$

Como X solo puede tomar los valores 0 y 1, se tiene

$$\varphi_X(t) = e^{it}\, P(X=1) + e^{i0t}\, P(X=0) = pe^{it} + (1-p).$$

Es decir,

$$\varphi_X(t) = (1-p) + pe^{it}.$$

(2) Si $Y \sim \text{Binomial}(N,p)$, entonces

Recordemos que una variable binomial puede escribirse como suma de variables Bernoulli i.i.d.:

$$Y = \sum_{j=1}^{N} Z_j, \qquad Z_j \overset{\text{i.i.d.}}{\sim} \text{Bernoulli}(p).$$

Luego,

$$\varphi_Y(t) = \mathbb{E}(e^{itY}) = \mathbb{E}\left(e^{it\sum_{j=1}^{N} Z_j}\right) = \mathbb{E}\left(\prod_{j=1}^{N} e^{itZ_j}\right).$$

Como las variables $Z_1, \ldots, Z_N$ son independientes, se obtiene

$$\varphi_Y(t) = \prod_{j=1}^{N} \mathbb{E}(e^{itZ_j}) = \prod_{j=1}^{N} \varphi_{Z_j}(t).$$

Como todas tienen la misma ley Bernoulli(p),

$$\varphi_Y(t) = \big(\varphi_{Z_1}(t)\big)^N = \big((1-p) + pe^{it}\big)^N.$$

Por tanto,

$$\varphi_Y(t) = \big((1-p) + pe^{it}\big)^N.$$

(3) Si $Z \sim \mathcal{N}(0,1)$, queremos calcular $\varphi_Z(t)$.

Más generalmente, si

$$W \sim \mathcal{N}(m, \sigma^2),$$

entonces puede escribirse como

$$W = m + \sigma Z, \qquad Z \sim \mathcal{N}(0,1).$$

Así,

$$\varphi_W(t) = \mathbb{E}(e^{itW}) = \mathbb{E}\big(e^{it(m+\sigma Z)}\big) = e^{imt}\mathbb{E}(e^{i\sigma t Z}).$$

Por definición de función característica,

$$\mathbb{E}(e^{i\sigma t Z}) = \varphi_Z(\sigma t).$$

Luego,

$$\varphi_W(t) = e^{imt}\varphi_Z(\sigma t).$$

Ahora bien, si $Z \sim \mathcal{N}(0,1)$, entonces

$$\varphi_Z(t) = e^{-t^2/2}.$$

Por consiguiente, si $W \sim \mathcal{N}(m, \sigma^2)$, se obtiene

$$\varphi_W(t) = e^{imt}\varphi_Z(\sigma t) = e^{imt}e^{-\sigma^2 t^2/2}.$$

Es decir,

$$\varphi_W(t) = \exp\left(imt - \frac{\sigma^2 t^2}{2}\right).$$

Observación: a diferencia de la función generadora de momentos

$$M_X(t) = \mathbb{E}(e^{tX}),$$

la función característica siempre está bien definida, pues

$$|e^{itX}| = 1.$$

Por lo tanto,

$$|\varphi_X(t)| = \big|\mathbb{E}(e^{itX})\big| \leq \mathbb{E}(|e^{itX}|) = 1.$$

En cambio, la función generadora de momentos puede no existir para todo t.

Teorema 1.2 (Unicidad de la función característica)**.** *Sean X e Y variables aleatorias con valores en $\mathbb{R}^d$. Si*

$$\varphi_X(t) = \varphi_Y(t), \qquad \forall t \in \mathbb{R}^d,$$

entonces

$$P_X = P_Y.$$

Proposición: sea X una variable aleatoria real.

(1) Si $k \in \mathbb{N}$ y

$$\mathbb{E}(|X|^k) < \infty,$$

entonces φ_X es k-veces derivable y, para todo $j = 1, \ldots, k$,

$$\varphi_X^{(j)}(t) = \mathbb{E}\big((iX)^j e^{itX}\big).$$

En particular,

$$\varphi_X^{(j)}(0) = i^j \mathbb{E}(X^j), \qquad j = 1, \ldots, k.$$

(2) Recíprocamente, si φ_X es k-veces derivable en un entorno de 0, con k par, entonces

$$\mathbb{E}(|X|^k) < \infty,$$

y además

$$\mathbb{E}(X^j) = (-i)^j \varphi_X^{(j)}(0), \qquad j = 1, \ldots, k.$$

1.11. Esperanza condicional

La esperanza condicional se define de manera natural a partir del Teorema de Radon–Nikodym.

Definición 1.9 (Esperanza condicional respecto de una σ-álgebra)**.** Sea $X \in L^1(\Omega, \mathcal{F}, P)$ y sea $\mathcal{G} \subseteq \mathcal{F}$ una sub-σ-álgebra. Diremos que una variable aleatoria Y es una **esperanza condicional** de X respecto de $\mathcal{G}$ si:

- Y es $\mathcal{G}$-medible,
- para todo $A \in \mathcal{G}$,
$$\int_A X(\omega)\, dP(\omega) = \int_A Y(\omega)\, dP(\omega).$$

En ese caso escribimos

$$Y = \mathbb{E}(X \mid \mathcal{G}).$$

Equivalentemente, la condición anterior puede escribirse como

$$\mathbb{E}(X \mathbb{1}_A) = \mathbb{E}\big(\mathbb{E}(X \mid \mathcal{G}) \mathbb{1}_A\big), \qquad \forall A \in \mathcal{G}.$$

Teorema 1.3 (Existencia y unicidad)**.** *Si $X \in L^1(\Omega, \mathcal{F}, P)$ y $\mathcal{G} \subseteq \mathcal{F}$ es una sub-σ-álgebra, entonces existe una variable aleatoria*

$$\mathbb{E}(X \mid \mathcal{G})$$

y es única casi seguramente.

Idea de la construcción: definimos una medida con signo sobre $\mathcal{G}$ mediante

$$\mu(A) = \int_A X\, dP, \qquad A \in \mathcal{G}.$$

Entonces $\mu \ll P|_{\mathcal{G}}$, y por Radon–Nikodym existe una variable aleatoria $\mathcal{G}$-medible Y tal que

$$\mu(A) = \int_A Y\, dP, \qquad \forall A \in \mathcal{G}.$$

Esa variable es precisamente $\mathbb{E}(X \mid \mathcal{G})$.

Primeros ejemplos

- Si
$$\mathcal{G} = \{\varnothing, \Omega\},$$
entonces toda variable $\mathcal{G}$-medible es constante casi seguramente, y se obtiene
$$\mathbb{E}(X \mid \mathcal{G}) = \mathbb{E}(X).$$

- Si
$$\mathcal{G} = \mathcal{F},$$
entonces X es $\mathcal{G}$-medible, por lo que
$$\mathbb{E}(X \mid \mathcal{F}) = X.$$

Propiedades

Sea $X, Y \in L^1(\Omega, \mathcal{F}, P)$ y sea $\mathcal{G} \subseteq \mathcal{F}$ una sub-σ-álgebra.

(1) **Monotonía.** Si
$$X \leq Y \quad \text{casi seguramente,}$$
entonces
$$\mathbb{E}(X \mid \mathcal{G}) \leq \mathbb{E}(Y \mid \mathcal{G}) \quad \text{casi seguramente.}$$

(2) **Esperanza total.**
$$\mathbb{E}\big(\mathbb{E}(X \mid \mathcal{G})\big) = \mathbb{E}(X).$$

(3) **Si X es $\mathcal{G}$-medible, entonces**
$$\mathbb{E}(X \mid \mathcal{G}) = X \quad \text{casi seguramente.}$$
En particular,
$$\mathbb{E}(X \mid \mathcal{F}) = X.$$

(4) **Linealidad.** Si $\alpha, \beta \in \mathbb{R}$, entonces
$$\mathbb{E}(\alpha X + \beta Y \mid \mathcal{G}) = \alpha \mathbb{E}(X \mid \mathcal{G}) + \beta \mathbb{E}(Y \mid \mathcal{G}).$$

(5) **Sacar lo conocido.** Si Z es una variable aleatoria $\mathcal{G}$-medible y acotada, entonces
$$\mathbb{E}(ZX \mid \mathcal{G}) = Z\,\mathbb{E}(X \mid \mathcal{G}).$$

(6) **Propiedad de Jensen.** Si $\phi : \mathbb{R} \to \mathbb{R}$ es convexa y $\phi(X) \in L^1$, entonces
$$\phi(\mathbb{E}(X \mid \mathcal{G})) \leq \mathbb{E}(\phi(X) \mid \mathcal{G}) \quad \text{casi seguramente.}$$

Observación: tomando esperanza en Jensen, se recupera la desigualdad clásica

$$\phi(\mathbb{E}(X)) \leq \mathbb{E}(\phi(X)).$$

En particular, tomando $\phi(x) = x^2$, se obtiene

$$(\mathbb{E}(X))^2 \leq \mathbb{E}(X^2),$$

y por lo tanto

$$\mathrm{Var}(X) = \mathbb{E}(X^2) - (\mathbb{E}(X))^2 \geq 0.$$

Propiedad de la torre: si

$$\mathcal{H} \subseteq \mathcal{G} \subseteq \mathcal{F},$$

entonces

$$\mathbb{E}\big(\mathbb{E}(X \mid \mathcal{G}) \mid \mathcal{H}\big) = \mathbb{E}(X \mid \mathcal{H}).$$

Además, como $\mathbb{E}(X \mid \mathcal{H})$ es $\mathcal{H}$-medible y $\mathcal{H} \subseteq \mathcal{G}$, se tiene

$$\mathbb{E}\big(\mathbb{E}(X \mid \mathcal{H}) \mid \mathcal{G}\big) = \mathbb{E}(X \mid \mathcal{H}).$$

Observación en L^2: si $X \in L^2(\Omega, \mathcal{F}, P)$, entonces

$$\mathbb{E}(X \mid \mathcal{G}) \in L^2(\Omega, \mathcal{G}, P),$$

y más aún,

$$\mathbb{E}(X \mid \mathcal{G}) = \mathrm{Proj}_{L^2(\Omega,\mathcal{G},P)}(X),$$

es decir, la esperanza condicional es la proyección ortogonal de X sobre el subespacio $L^2(\Omega, \mathcal{G}, P)$.

Observación: si X es independiente de $\mathcal{G}$, entonces

$$\mathbb{E}(X \mid \mathcal{G}) = \mathbb{E}(X).$$

Condicionar respecto de una variable aleatoria

Si Y es una variable aleatoria real, denotamos por

$$\sigma(Y)$$

la menor σ-álgebra que hace a Y medible. En ese caso escribimos

$$\mathbb{E}(X \mid Y) \quad \text{en lugar de} \quad \mathbb{E}(X \mid \sigma(Y)).$$

Teorema 1.4 (Doob–Dynkin)**.** *Si X es una variable aleatoria $\sigma(Y)$-medible, entonces existe una función medible*

$$f : \mathbb{R} \to \mathbb{R}$$

tal que

$$X = f(Y) \quad \textit{casi seguramente.}$$

Como $\mathbb{E}(X \mid Y)$ es $\sigma(Y)$-medible, el teorema anterior implica que existe una función medible f tal que

$$\mathbb{E}(X \mid Y) = f(Y).$$

Muchas veces, de manera informal, se escribe

$$\mathbb{E}(X \mid Y = y) = f(y),$$

entendiendo que se ha escogido una versión de $\mathbb{E}(X \mid Y)$ de la forma $f(Y)$.

Cálculo mediante la ley de Y

Usando la propiedad de la esperanza total,

$$\mathbb{E}(X) = \mathbb{E}\big(\mathbb{E}(X \mid Y)\big).$$

Si Y es discreta con soporte $\{y_k\}_{k\in I}$, entonces

$$\mathbb{E}(X) = \sum_{k\in I} \mathbb{E}(X \mid Y = y_k)\, P(Y = y_k).$$

Si Y es absolutamente continua con densidad f_Y, entonces

$$\mathbb{E}(X) = \int_{\mathbb{R}} \mathbb{E}(X \mid Y = y)\, f_Y(y)\, dy.$$

Ejemplo

Sea

$$Y \sim \mathcal{U}(0,1),$$

y supongamos que, condicionado a $Y = y$, la variable X satisface

$$X = \begin{cases} 1, & \text{con probabilidad } y, \\ 0, & \text{con probabilidad } 1 - y. \end{cases}$$

Entonces, para cada $y \in (0,1)$,

$$\mathbb{E}(X \mid Y = y) = y.$$

Por lo tanto,

$$\mathbb{E}(X \mid Y) = Y.$$

Aplicando esperanza total,

$$\mathbb{E}(X) = \mathbb{E}\big(\mathbb{E}(X \mid Y)\big) = \mathbb{E}(Y).$$

Como $Y \sim \mathcal{U}(0,1)$,

$$\mathbb{E}(Y) = \int_0^1 y\, dy = \frac{1}{2}.$$

En consecuencia,

$$\mathbb{E}(X) = \frac{1}{2}.$$

Recordatorio: si Y es una variable aleatoria discreta y y satisface $P(Y = y) > 0$, entonces puede escribirse

$$\mathbb{E}(X \mid Y = y) = \frac{\mathbb{E}(X \mathbb{1}_{\{Y=y\}})}{P(Y = y)}.$$

Además, si $\{B_u\}_{u\in I}$ es una partición medible de Ω con $P(B_u) > 0$, entonces para todo evento $A \in \mathcal{F}$,

$$P(A) = \sum_{u\in I} P(A \mid B_u)\, P(B_u),$$

que es la fórmula de probabilidades totales.

Interpretación: la variable aleatoria $\mathbb{E}(X \mid Y)$ representa la mejor predicción de X cuando se conoce la información contenida en Y.

Recordemos algunas identidades básicas:

(1)
$$\mathbb{E}(X) = \mathbb{E}(X \mid \{\varnothing, \Omega\}).$$

(2)
$$\mathbb{E}(X \mid \mathcal{F}) = X.$$

(3) $\mathbb{E}(X \mid Y)$ es una variable aleatoria $\sigma(Y)$-medible.

(4) Si existe una versión de $\mathbb{E}(X \mid Y)$ de la forma $f(Y)$, entonces se escribe informalmente
$$\mathbb{E}(X \mid Y = y) = f(y).$$

(5) Se tiene la fórmula de la esperanza total:
$$\mathbb{E}(X) = \mathbb{E}(\mathbb{E}(X \mid Y)).$$

Más explícitamente, si existe una versión $y \mapsto \mathbb{E}(X \mid Y = y)$, entonces
$$\mathbb{E}(X) = \int_{\mathbb{R}} \mathbb{E}(X \mid Y = y)\, P_Y(dy).$$

Ejemplo

Sea
$$Y \sim \mathcal{U}(0,1),$$
y supongamos que, condicionado a $Y = y$, la variable X verifica
$$X = \begin{cases} 1, & \text{con probabilidad } y, \\ 0, & \text{con probabilidad } 1 - y. \end{cases}$$

Entonces
$$\mathbb{E}(X \mid Y = y) = y.$$
Por lo tanto,
$$\mathbb{E}(X \mid Y) = Y.$$
Luego, por la fórmula de la esperanza total,
$$\mathbb{E}(X) = \mathbb{E}(\mathbb{E}(X \mid Y)) = \mathbb{E}(Y) = \frac{1}{2}.$$

Proposición: si X e Y son variables aleatorias independientes, entonces
$$\mathbb{E}(X \mid Y) = \mathbb{E}(X).$$

Demostración: la variable $\mathbb{E}(X)$ es constante, luego es $\sigma(Y)$-medible. Además, para todo $A \in \sigma(Y)$,
$$\mathbb{E}(X \mathbb{1}_A) = \mathbb{E}(X)\mathbb{E}(\mathbb{1}_A) = \mathbb{E}(X)P(A) = \mathbb{E}\big(\mathbb{E}(X)\mathbb{1}_A\big).$$

Por unicidad casi segura de la esperanza condicional,

$$\mathbb{E}(X \mid Y) = \mathbb{E}(X).$$

□

Más generalmente, si Z es $\sigma(Y)$-medible y acotada, entonces

$$\mathbb{E}(XZ \mid Y) = Z\,\mathbb{E}(X \mid Y).$$

En particular, si además $X \perp Y$, entonces

$$\mathbb{E}(XZ \mid Y) = Z\,\mathbb{E}(X).$$

Ejemplo

Sean X, Y variables aleatorias i.i.d. y definamos

$$Z = X + Y.$$

Queremos calcular $\mathbb{E}(X \mid Z)$.

Como X e Y tienen la misma ley y Z es simétrica en X e Y, se tiene

$$\mathbb{E}(X \mid Z) = \mathbb{E}(Y \mid Z).$$

Por linealidad,

$$\mathbb{E}(X + Y \mid Z) = \mathbb{E}(X \mid Z) + \mathbb{E}(Y \mid Z).$$

Pero como $Z = X + Y$ es $\sigma(Z)$-medible,

$$\mathbb{E}(X + Y \mid Z) = Z.$$

Entonces

$$Z = 2\,\mathbb{E}(X \mid Z),$$

y por tanto

$$\mathbb{E}(X \mid Z) = \frac{Z}{2}.$$

Ejemplo

Sean X, Y variables aleatorias i.i.d. con ley $\mathcal{U}(0,1)$, y definamos

$$Z = \text{mín}\{X, Y\}.$$

Queremos calcular $\mathbb{E}(Z \mid X)$ y deducir $\mathbb{E}(Z)$.

Como Y es independiente de X, para $x \in [0,1]$ se tiene

$$\mathbb{E}(Z \mid X = x) = \mathbb{E}(\text{mín}\{x, Y\}).$$

Ahora,

$$\text{mín}\{x, Y\} = \begin{cases} Y, & \text{si } Y \leq x, \\ x, & \text{si } Y > x. \end{cases}$$

Como $Y \sim \mathcal{U}(0,1)$,

$$\mathbb{E}(\text{mín}\{x, Y\}) = \int_0^x y\,dy + \int_x^1 x\,dy = \frac{x^2}{2} + x(1-x) = x - \frac{x^2}{2}.$$

Luego,

$$\mathbb{E}(Z \mid X) = X - \frac{X^2}{2}.$$

Aplicando esperanza total,

$$\mathbb{E}(Z) = \mathbb{E}(\mathbb{E}(Z \mid X)) = \mathbb{E}\left(X - \frac{X^2}{2}\right).$$

Como $X \sim \mathcal{U}(0,1)$,

$$\mathbb{E}(X) = \frac{1}{2}, \qquad \mathbb{E}(X^2) = \int_0^1 x^2\,dx = \frac{1}{3}.$$

Por consiguiente,

$$\mathbb{E}(Z) = \frac{1}{2} - \frac{1}{2} \cdot \frac{1}{3} = \frac{1}{3}.$$

1.12. Modos de convergencia

Sean $(X_n)_{n\in\mathbb{N}}$ y X variables aleatorias con valores en $\mathbb{R}^d$.

(1) Convergencia casi segura

Decimos que

$$X_n \xrightarrow{c.s.} X$$

si

$$P\big(\{\omega \in \Omega : \; X_n(\omega) \to X(\omega)\}\big) = 1.$$

Equivalentemente,

$$P\left(\{\omega \in \Omega : \forall \varepsilon > 0, \; \exists N(\omega) \in \mathbb{N} \text{ tal que } n \geq N(\omega) \Rightarrow |X_n(\omega) - X(\omega)| < \varepsilon\}\right) = 1.$$

Ejemplo: si $(X_n)_{n\in\mathbb{N}}$ son i.i.d. y $\mathbb{E}(|X_1|) < \infty$, entonces

$$\frac{1}{n}\sum_{i=1}^n X_i \xrightarrow{c.s.} \mathbb{E}(X_1).$$

Este es el contenido de la ley fuerte de los grandes números.

(2) Convergencia en probabilidad

Decimos que

$$X_n \xrightarrow{P} X$$

si para todo $\varepsilon > 0$,

$$P(|X_n - X| \geq \varepsilon) \xrightarrow[n\to\infty]{} 0.$$

Observación:

$$X_n \xrightarrow{c.s.} X \quad \Longrightarrow \quad X_n \xrightarrow{P} X.$$

Proposición 1.1 (Desigualdad de Markov)**.** *Sea Y una variable aleatoria real no negativa casi seguramente. Entonces, para todo $a > 0$,*

$$P(Y \geq a) \leq \frac{\mathbb{E}(Y)}{a}.$$

Demostración: como $Y \geq 0$ casi seguramente,

$$\mathbb{E}(Y) = \int_\Omega Y \, dP \geq \int_{\{Y \geq a\}} Y \, dP.$$

Pero en el conjunto $\{Y \geq a\}$ se tiene $Y \geq a$, así que

$$\int_{\{Y \geq a\}} Y \, dP \geq a \, P(Y \geq a).$$

Por lo tanto,

$$\mathbb{E}(Y) \geq a \, P(Y \geq a),$$

y de aquí se concluye que

$$P(Y \geq a) \leq \frac{\mathbb{E}(Y)}{a}.$$

□

Corolario: si $Y \in L^p$ con $p \geq 1$, entonces para todo $a > 0$,

$$P(|Y| \geq a) \leq \frac{\mathbb{E}(|Y|^p)}{a^p}.$$

Demostración: basta aplicar Markov a la variable no negativa $|Y|^p$. □

Proposición 1.2 (Desigualdad de Chebyshev)**.** *Si $X \in L^2$, entonces para todo $\varepsilon > 0$,*

$$P(|X - \mathbb{E}(X)| \geq \varepsilon) \leq \frac{\mathrm{Var}(X)}{\varepsilon^2}.$$

Demostración: aplicamos Markov a la variable

$$Y = (X - \mathbb{E}(X))^2,$$

que es no negativa. Entonces

$$P\big((X - \mathbb{E}(X))^2 \geq \varepsilon^2\big) \leq \frac{\mathbb{E}\big((X - \mathbb{E}(X))^2\big)}{\varepsilon^2} = \frac{\mathrm{Var}(X)}{\varepsilon^2}.$$

Como

$$\{(X - \mathbb{E}(X))^2 \geq \varepsilon^2\} = \{|X - \mathbb{E}(X)| \geq \varepsilon\},$$

se concluye el resultado. □

Ejemplo: ley débil de los grandes números en L^2

Sean $(X_n)_{n\in\mathbb{N}}$ variables aleatorias i.i.d. con $X_1 \in L^2$, y definamos

$$\overline{X}_n = \frac{1}{n}\sum_{i=1}^{n} X_i.$$

Entonces

$$\overline{X}_n \xrightarrow{P} \mathbb{E}(X_1).$$

En efecto, por Chebyshev,

$$P\big(|\overline{X}_n - \mathbb{E}(X_1)| \geq \varepsilon\big) \leq \frac{\mathrm{Var}(\overline{X}_n)}{\varepsilon^2}.$$

Como las variables son i.i.d.,

$$\mathrm{Var}(\overline{X}_n) = \mathrm{Var}\left(\frac{1}{n}\sum_{i=1}^{n} X_i\right) = \frac{1}{n^2}\sum_{i=1}^{n}\mathrm{Var}(X_i) = \frac{\mathrm{Var}(X_1)}{n}.$$

Luego,

$$P\big(|\overline{X}_n - \mathbb{E}(X_1)| \geq \varepsilon\big) \leq \frac{\mathrm{Var}(X_1)}{n\varepsilon^2} \xrightarrow[n\to\infty]{} 0.$$

Por tanto,

$$\overline{X}_n \xrightarrow{P} \mathbb{E}(X_1).$$

(3) Convergencia en L^p

Sea $p \geq 1$. Diremos que

$$X_n \xrightarrow{L^p} X$$

si

$$\mathbb{E}(|X_n - X|^p) \xrightarrow[n\to\infty]{} 0.$$

Equivalentemente,

$$\|X_n - X\|_p \to 0, \qquad \text{donde } \|Z\|_p := \big(\mathbb{E}(|Z|^p)\big)^{1/p}.$$

Observación: si

$$X_n \xrightarrow{L^p} X,$$

entonces necesariamente $X \in L^p$.

Además, por el corolario de Markov,

$$P(|X_n - X| \geq \varepsilon) \leq \frac{\mathbb{E}(|X_n - X|^p)}{\varepsilon^p}.$$

Por lo tanto,

$$X_n \xrightarrow{L^p} X \quad \Longrightarrow \quad X_n \xrightarrow{P} X.$$

Teorema 1.5 (Convergencia dominada en L^p)**.** *Sea $p \geq 1$. Si*

$$X_n \xrightarrow{c.s.} X$$

y existe $Y \in L^p$ tal que

$$|X_n| \leq Y \quad \textit{casi seguramente, para todo } n \in \mathbb{N},$$

entonces

$$X_n \xrightarrow{L^p} X.$$

Demostración: como $X_n \to X$ casi seguramente y $|X_n| \leq Y$, se tiene también

$$|X| \leq Y \quad \text{casi seguramente.}$$

Luego,

$$|X_n - X|^p \to 0 \quad \text{casi seguramente.}$$

Además,

$$|X_n - X|^p \leq (|X_n| + |X|)^p \leq (2Y)^p.$$

Como $Y \in L^p$, se tiene $(2Y)^p \in L^1$. Aplicando el Teorema de Convergencia Dominada,

$$\mathbb{E}(|X_n - X|^p) \to 0.$$

Esto significa precisamente que

$$X_n \xrightarrow{L^p} X.$$

□

Observación: en particular, el caso $p = 1$ recupera la convergencia dominada clásica.

Otra consecuencia: si $X_n \xrightarrow{L^p} X$ con $p \geq 1$, entonces

$$\mathbb{E}(|X_n|^p) \to \mathbb{E}(|X|^p).$$

En efecto, $\|X_n - X\|_p \to 0$ implica $\|X_n\|_p \to \|X\|_p$, y por ende

$$\mathbb{E}(|X_n|^p) = \|X_n\|_p^p \to \|X\|_p^p = \mathbb{E}(|X|^p).$$

Además, como estamos en un espacio de probabilidad, si $p \geq 1$ entonces

$$\|Z\|_1 \leq \|Z\|_p.$$

Por tanto,

$$X_n \xrightarrow{L^p} X \quad \Longrightarrow \quad X_n \xrightarrow{L^1} X,$$

y en consecuencia

$$\mathbb{E}(X_n) \to \mathbb{E}(X).$$

(4) Convergencia en ley

Diremos que

$$X_n \xrightarrow{\mathcal{L}} X$$

si para toda función continua y acotada

$$f : \mathbb{R}^d \to \mathbb{R},$$

se tiene

$$\mathbb{E}(f(X_n)) \xrightarrow[n\to\infty]{} \mathbb{E}(f(X)).$$

Equivalentemente, la sucesión de leyes P_{X_n} converge débilmente hacia P_X.

Observación: la convergencia en ley también se denomina **convergencia débil de leyes**.

Observación: si

$$X_n \xrightarrow{P} X,$$

entonces

$$X_n \xrightarrow{\mathcal{L}} X.$$